

Plano Quant Revisado para Bot de Daytrade em Índices

WIN, séries temporais financeiras, validação temporal, backtest realista e prevenção de data leakage

Campo	Valor
Projeto	win_bot
Versão	Plano técnico revisado v1
Data	5 de junho de 2026
Escopo	Pesquisa, dados, features, labels, validação e backtest. Sem execução real nesta fase.
Postura	Quant researcher + ML engineer sênior, com prioridade para robustez temporal.

Decisão central revisada

O objetivo inicial não é criar um bot que opere. O objetivo é criar um ambiente de pesquisa que não se engane: dados auditáveis, features sem futuro, labels que representem trades possíveis, validação walk-forward e backtest com custos. Só depois disso faz sentido pensar em shadow, demo e real.

1. Resumo executivo

Este documento reescreve o plano original como um roteiro de pesquisa quantitativa e engenharia de ML para daytrade em índices, especialmente WIN. A prioridade é evitar conclusões falsas antes de qualquer busca por performance.

- Começar por dados e validação, não por modelo.
- Manter o projeto intraday, sem overnight e sem scalping de microestrutura usando apenas OHLCV.
- Usar M5/M15/M30 para eventos e execução simulada; H1/H4/D1 apenas como contexto fechado e alinhado no tempo.
- Tratar custos, spread, slippage, horário, limites de trade e zeragem como parte do problema.
- Só avançar para shadow, demo e real depois que o backtest sobreviver a validações temporais e stress de custo.

O que esperar

As primeiras etapas não vão produzir um modelo vencedor. Elas vão produzir confiança sobre o que o dataset permite afirmar. Esse progresso parece lento, mas impede meses de pesquisa em cima de vazamento ou backtest fantasioso.

2. Estado atual observado no projeto

O repositório já possui uma fundação inicial útil: coleta via MetaTrader 5, CSVs brutos por timeframe, preprocessing e features básicas de gap. A próxima etapa correta é auditar qualidade antes de criar labels ou modelos.

Item	Estado atual	Implicação técnica
Coleta MT5	Script para WIN\$N, 4 anos, D1/H4/H1/M30/M15/M5.	Bom ponto de partida, mas o histórico depende da corretora e do servidor MT5.
Dados brutos	CSVs em data/raw.	Raw deve ser tratado como fonte congelável; não deve ser sobrescrito sem snapshot.
Preprocessing	Lê data/raw, normaliza datetime, cria data/processed.	Fluxo correto para separar dado bruto de artefato derivado.
Gap features	minutes_since_prev, has_time_gap, gap_points, gap_pct, gap_abs, gap_direction.	Boa decisão: medir gaps sem inventar candles.
M5	100.000 candles, começando depois dos timeframes maiores.	Provável limite de histórico MT5. Precisa entrar no relatório de qualidade.
D1	Datetime convertido pode aparecer fora do horário intuitivo do pregão.	Validar timezone e semântica do candle diário antes de usar D1 em features.

3. Princípios de pesquisa

- 1 Todo valor de feature precisa estar conhecido no instante da decisão.
- 2 Todo split deve respeitar o tempo; split aleatório é proibido para medir performance financeira.
- 3 Todo pré-processamento com parâmetros aprendidos deve ser fitado apenas no treino da janela walk-forward.
- 4 Todo label deve representar um trade executável depois do sinal, com custo, spread e slippage.
- 5 Todo modelo precisa vencer baselines simples e sobreviver a stress de custo.
- 6 Toda conclusão deve ser avaliada por janela, mês, horário, regime e sensibilidade.
- 7 Nenhuma ordem real deve existir antes de shadow mode, demo e logs operacionais completos.

4. Arquitetura alvo

A arquitetura deve separar pesquisa de execução. O mesmo dataset não deve servir ao mesmo tempo para descobrir hipóteses, otimizar parâmetros e declarar resultado final.

Camada	Responsabilidade	Validação mínima
Raw data	CSV original por timeframe, sem transformação destrutiva.	Hash/snapshot, schema MT5, range de datas.
Quality report	Detectar buracos, duplicatas, dias incompletos, volume/spread suspeitos.	Relatório salvo e revisado antes de features novas.
Processed data	Datetime, ordenação, deduplicação e features determinísticas básicas.	Reprodutibilidade e contagem esperada.
Feature dataset	Features leakage-safe por evento de decisão.	Auditoria feature por feature: conhecida ou não conhecida no timestamp.
Label dataset	Triple barrier e targets auxiliares separados das features.	Amostras manuais e casos ambíguos revisados.
Research backtest	Simulação conservadora e repetível.	Entrada no próximo candle, custos, slippage, horários e limites.
Shadow/demo	Rodar sinais e ordens simuladas/ambiente demo.	Logs comparáveis ao backtest candle a candle.

5. Sequência prática de desenvolvimento

A ordem abaixo é deliberadamente conservadora. Ela reduz o risco de construir um modelo sofisticado em cima de uma medição errada.

Fase	Marco	Foco	O que esperar
0	Contrato de escopo	Definir símbolo, timeframes, timezone, horário de pregão, custos e restrições.	Documento curto de premissas. Não há modelo aqui.
1	Qualidade dos dados	Auditando data/raw e data/processed.	Relatório com gaps, duplicatas, candles por dia, volume e spread.
2	Features v1	Tempo, sessão, gap, retornos, range, ATR, volume/spread e níveis intraday.	Dataset com features auditadas contra leakage.
3	Evento de decisão	Definir quando o modelo decide e onde a entrada ocorreria.	Tabela com decision_time, entry_time, preço e horizonte.
4	Labels	Triple barrier com custo e slippage, mais targets auxiliares.	Distribuição de classes e revisão manual de amostras.
5	Baseline sem ML	Estratégias simples e aleatórias filtradas por horário.	Benchmark mínimo que o ML precisa superar.
6	Walk-forward ML	LightGBM/CatBoost simples, purging/embargo quando necessário.	Resultados por janela, calibração e stress de custo.
7	Backtest conservador	Motor de simulação com regras operacionais.	PnL líquido, drawdown, expectativa, resultado por regime.
8	Shadow/demo	Sinais sem ordem real, depois demo com 1 contrato.	Logs completos e comparação contra backtest.
9	Real mínimo	Somente se demo e backtest forem consistentes.	1 contrato, risco pequeno, kill switch e critérios de desligamento.

6. Riscos críticos e controles

Risco	Como aparece	Controle obrigatório
Look-ahead bias	Usar fechamento do candle que ainda não terminou ou candle maior em formação.	Sinal só pode usar candles fechados; multi-timeframe via merge_asof com deslocamento correto.
Data leakage	Normalizar, selecionar features ou calibrar thresholds usando todo o dataset.	Fit apenas dentro do treino de cada janela; teste final congelado.
Leakage de labels	MFE, MAE, retorno futuro ou label_end_time entram como feature.	Separar colunas diagnósticas e bloquear qualquer coluna futura no feature set.
Overfitting	Muitos indicadores, modelos e hiperparâmetros testados até achar sorte.	Baseline, ablation, controle de experimentos e métricas por janela.
Backtest irrealista	Entrada no fechamento do candle usado para gerar sinal; alvo e stop resolvidos de forma otimista.	Entrada no próximo candle; se alvo e stop no mesmo OHLC, assumir pior caso ou usar timeframe menor.
Métrica enganosa	Accuracy alta ou PnL positivo agregado sem estabilidade.	Expectancy líquido, drawdown, calibração, resultado por mês/regime/horário e stress de slippage.
Execução prematura	Conectar ordens antes de logs e validação temporal.	Shadow mode, demo, kill switch e bloqueio explícito de execução real nas fases iniciais.

7. Protocolo de dados

- Raw data é imutável por definição. Nova coleta deve gerar snapshot por data ou hash e período coletado.
- Processed data é artefato gerado. Pode ser sobrescrito, mas precisa ser reproduzível.
- Todo timeframe deve ter schema validado: time, open, high, low, close, tick_volume, spread, real_volume.
- Timezone precisa ser único no projeto. Preservar timestamp Unix original e usar America/Sao_Paulo no dataset de pesquisa.
- Gaps normais de mercado não devem ser preenchidos. Eles devem virar features e diagnósticos.
- Rollover e contrato contínuo devem ser documentados. WIN\$N pode ter regra dependente da corretora.

8. Features v1 sem vazamento

Grupo	Entram primeiro	Cuidados
Tempo e sessão	hour, minute, day_of_week, minutes_since_open, minutes_to_close.	Só usar calendário conhecido. Validar feriados e pregões encurtados.
Gap	minutes_since_prev, has_time_gap, is_session_start, gap_points, gap_pct, gap_abs, gap_direction.	Gap usa open atual e close anterior; sinal de trade só pode ocorrer depois do candle de decisão estar definido.
Retornos	return_1, log_return_1, retornos em 3/6/12 candles.	Somente passado. Nunca retorno futuro no feature set.
Candle/range	body, wick, high_low_range, close_position_in_range.	Baseado em candle fechado; para entrada no mesmo candle, isso vaza.
Volatilidade	true_range, ATR, rolling_std, realized_vol.	Janelas rolling passadas; ATR usado no label deve ser calculado antes do evento.
Volume/spread	volume_zscore, relative_volume, spread_zscore.	Z-score fitado apenas com passado/janela de treino. real_volume pode ser inválido.
Níveis intraday	day_open, high_so_far, low_so_far, previous_day_close.	high_so_far/low_so_far só com candles já fechados; opening range só depois do intervalo completo.
Multi-timeframe	trend_H1, volatility_H1, return_H4, contexto D1.	Candle maior precisa estar fechado ou ser tratado explicitamente como parcial.

9. Labels e eventos de trade

O label deve começar pela definição do evento. Sem evento claro, o modelo aprende uma mistura de direção, timing e execução que não corresponde a uma operação real.

- 1 Escolher o timeframe de decisão inicial, preferencialmente M15 para direção e M5 para resolução de execução.
- 2 Definir decision_time como o fechamento do candle que gera as features.
- 3 Definir entry_time como o próximo candle ou o próximo preço disponível com slippage.
- 4 Calcular ATR/volatilidade usando apenas candles anteriores ao evento.
- 5 Definir barreira superior, inferior e vertical antes de olhar o futuro.
- 6 Aplicar custo, spread e slippage ao resultado líquido.
- 7 Guardar diagnósticos de label fora do feature set: MFE, MAE, tempo até saída, motivo de saída.

Preferência técnica

Rodar dois caminhos em paralelo somente depois da auditoria de dados: A) classificação direta 3-classes em todos os eventos elegíveis; B) setup candidato simples + meta-labeling. Para operação real, o caminho B tende a reduzir overtrading e ruído.

10. Protocolo de backtest realista

- Entrada nunca ocorre no fechamento usado para gerar o sinal. Usar próximo candle ou preço modelado com slippage.

- Se alvo e stop aparecem no mesmo candle OHLC e não há granularidade menor, assumir o pior caso.
- Incluir spread, custos, slippage base e stress de slippage 2x ou maior.
- Impor horário permitido, bloqueio de abertura se necessário, zeragem antes do fechamento e limite de trades por dia.
- Não permitir aumento automático de mão, pyramiding ou recuperação de perda na primeira versão.
- Comparar contra baselines: aleatório filtrado por horário, breakout simples e estratégia sem ML.
- Separar resultado por mês, horário, dia da semana, regime, volatilidade e custo.

11. Métricas que importam

Categoria	Métricas úteis	Armadilhas
ML	Brier score, curva de calibração, PR-AUC, precision/recall da classe operável, F1 por classe.	Accuracy alta pode ser inútil se a maioria dos candles não é trade.
Trading	PnL líquido, expectancy por trade, profit factor, max drawdown, drawdown diário, trades por dia.	PnL agregado pode depender de poucos dias extremos.
Robustez	Resultado por mês, janela walk-forward, horário, regime e stress de slippage.	Média final esconde instabilidade temporal.
Operacional	Slippage médio, fills, ordens recusadas, tempo em posição, stops consecutivos.	Backtest sem log operacional não prepara demo/real.

12. Deep learning, notícias e LLM

- Deep learning não entra no início. Com OHLCV, modelos tabulares bem validados são mais rápidos de auditar.
- TCN/1D CNN só fazem sentido depois de baseline tabular, ablation e walk-forward estáveis.
- DeepLOB exige book/tick/agressão; não deve ser simulado com candles comuns.
- Notícias e LLM entram primeiro como filtro de risco, não como gerador de compra/venda.
- Calendário econômico deve vir antes de LLM: eventos conhecidos são mais fáceis de bloquear e validar.

13. Primeira etapa recomendada: Data Quality Report v1

Esta é a próxima etapa prática. Ela deve ser concluída antes de novas features, labels ou modelos.

Subtarefa	Motivo técnico	Critério de conclusão
Schema	Evita CSV errado ou coluna ausente entrando silenciosamente.	Todas as colunas MT5 obrigatórias validadas por timeframe.
Range temporal	Define exatamente o período pesquisável.	Primeiro/último timestamp por timeframe e interseção comum.
Duplicatas	Duplicatas distorcem retornos, gaps e contagem de candles.	Quantidade detectada e regra de remoção documentada.
Candles por dia	Identifica dias incompletos e buracos anormais.	Tabela diária por timeframe com dias suspeitos marcados.
Gaps	Separa pausa normal de falha de dado.	Distribuição de minutes_since_prev e lista de gaps extremos.
Volume	real_volume pode ser zerado ou inconsistente.	Percentual de zeros e decisão de uso como feature.
Spread	Custo operacional muda muito por horário.	Média, p95, máximo e janelas de spread anormal.
Timezone	Erro de fuso cria features de sessão falsas.	Amostras conferidas contra horário esperado do pregão.
Raw vs processed	Garante reprodutibilidade.	Contagens e colunas comparadas entre raw e processed.

14. Arquivos prováveis da primeira etapa

- win_bot/data_quality.py: auditoria de schema, datas, duplicatas, gaps, volume e spread.
- reports/data_quality/: relatórios gerados em Markdown/CSV/JSON.
- README.md: comando para rodar a auditoria e interpretar os outputs.
- tests/test_data_quality.py: testes pequenos para schema, duplicatas e gaps artificiais.

Regra de parada

A etapa 1 termina com uma decisão explícita: dados aprovados para features/labels, dados aprovados com ressalvas ou dados bloqueados para correção. Sem essa decisão, o projeto não deve avançar.

15. Checklist de milestones

Status	Milestone
[]	Contrato de dados e escopo operacional aprovado.
[]	Relatório de qualidade dos dados gerado e revisado.
[]	Raw data congelado ou versionado por snapshot.
[]	Processed data reproduzível a partir do raw.
[]	Features v1 auditadas contra leakage.
[]	Alinhamento multi-timeframe validado com candles fechados.
[]	Evento de decisão e entrada formalizado.
[]	Triple barrier implementado e revisado em amostras manuais.
[]	Baseline sem ML medido.
[]	Walk-forward com purging/embargo quando necessário.
[]	Primeiro modelo tabular treinado e calibrado.
[]	Ablation de features concluído.
[]	Backtest conservador com stress de custo aprovado.
[]	Shadow mode com logs completos.
[]	Demo validada antes de qualquer ordem real.

16. Critérios de avanço para demo e real

Etapa	Critério mínimo	Não avançar se
Pós-backtest	Resultado líquido positivo fora da amostra em várias janelas e não dependente de poucos dias.	O lucro some com slippage 2x ou aparece só em uma janela.
Pré-shadow	Pipeline reproduzível, logs de decisão e feature set congelado.	Ainda há mudanças manuais ou colunas suspeitas no dataset.
Pré-demo	Shadow mostra sinais compatíveis com backtest e sem erros de horário.	Sinais ao vivo divergem do backtest sem explicação.
Pré-real	Demo por semanas com logs completos, fills consistentes e drawdown dentro do esperado.	Demo ganha/perde por comportamento diferente do backtest ou há falha de execução.
Real 1 contrato	Risco pequeno, kill switch, stop diário, limite de trades e monitoramento.	Qualquer tentativa de aumentar mão para compensar perda.

17. O que não fazer agora

- Não conectar em corretora para enviar ordem real.
- Não usar API keys ou automatizar execução.
- Não treinar deep learning antes de baseline tabular e backtest estável.
- Não otimizar hiperparâmetros antes de definir métricas e walk-forward.
- Não adicionar notícias/LLM como sinal direcional principal.

- Não escolher features olhando performance global fora de um processo temporal.

18. Conclusão operacional

O plano revisado mantém a ambição do projeto, mas muda a ordem de prioridade: primeiro medir e blindar o pipeline contra autoengano, depois modelar. Para daytrade em índices, o inimigo principal é a combinação de dados imperfeitos, validação temporal fraca e backtest otimista. Se o projeto vencer essas etapas com disciplina, o ML passa a ser uma ferramenta útil; antes disso, é apenas uma máquina de confirmar ilusões.

Próximo passo

Implementar apenas a etapa 1: Data Quality Report v1. A saída esperada é um relatório objetivo sobre se os dados atuais estão prontos para features e labels.